

Meal Planning 데이터 전처리 과정 — 전체 현황

원천 데이터를 월 예산·냉장고·레시피 추천·장보기·알림에 사용할 수 있도록 수집, 정제, 검증하는 전 과정을 정리한다.

단계	대상	전처리 내용	상태	근거(저장소)
수집	공공 레시피	COOKRCP01-EPIS JSON/XML 파싱, source/source_recipe_id 유지	구현	pipelines/ingest/load_recipe.py
수집	상품·가격	컬리·오아시스 원천 이벤트를 Kafka raw topic으로 전달	구현	crawler/*, pipelines/stream
정규화	품목명	상품·재료·OCR 명칭을 ITEM_MASTER/ITEM_ALIAS로 표준화	구현·보강 중	retail_norm.py, gazetteer.py
정규화	수량·규격	g/kg·ml/L·개/팩을 분리하고 중량·용량·단가 계산	구현	quantity.py, backfill_volume_ml.py
정규화	레시피 재료	자유텍스트에서 재료·수량·비재료 여부와 순번 분리	구현	backfill_ner_raw_ingredients.py
정제	영수증 OCR	문자열·가격·수량·식품 여부를 구조화하고 사용자 confirmed 반영	구현	services/ocr
파생	소비가한	품목·보관방식 참조값으로 expire_at 재계산	구현	recompute_pantry_expire.py
파생	가격	원가·판매가·규격으로 할인율과 단위가격 계산, 이상가격 탐지	구현	detect_price_anomaly.py
적재	PostgreSQL	자연키/원천키 기반 upsert로 중복 없는 명등 적재	구현	pipelines/ingest/load_*.py
동기화	ES·Redis	레시피 검색 인덱스와 최신 가격·핫딜 캐시 갱신	구현	PGSync, index_recipes_es.py
검증	전체 데이터	PK/FK·필수값 범위·중복·시계열 불변식 검사	구현	data_invariants.py, tests
보호	사용자 데이터	활동 동의 확인 및 대화·행동 원문 보존기간 정리	구현	prune_user_data.py

식세 난세 선사리

항목	문제	결정	근거·예외
원천 식별자	재수집 시 동일 레시피·상품 중복 가능	source + source_recipe_id/source_product_id를 고유 기준으로 upsert	재실행해도 기존 테이블 행이 중복되지 않게 함
날짜·시간	소스별 시간대와 포맷 불일치	수집시각은 TIMESTAMPTZ, 지출일·만료일은 DATE로 변환	파싱 실패 원문은 오류 로그에 보존
숫자	가격·영양 값에 십표·단위·공백 포함	기호 제거 후 NUMERIC 변환, 결측은 NULL 유지	0으로 임의 대체하지 않음
가격 이력	동일 상품 가격이 시점별 반복	(retail_product_id, crawled_at) 복합키로 이력 보존	현재가 덮어쓰기 금지
레시피 순서	재료·조리단계가 배열/자유텍스트로 제공	recipe_ingredient.sequence와 recipe_step.step_number로 분리	레시피 안에서 순번 중복 검증
영수증	OCR 결과에 비식품·오인식 포함	is_food-confirmed로 사용자 확인 전후를 구분	확정 항목만 재고·지출 반영
보존 메타	수집 출처와 시점을 잃으면 재현 불가	source-fetched_at-first_seen_at-last_seen_at 저장	수집 경로 추적 가능

데시파·상썸 데이터 전처리

관련 항목간의 기본 링크
ITEM_MASTER를 중심으로 연결한다.

소스/테이블	전처리 항목	내용	근거	상태
recipe	원천 중복	source_recipe_id 기준 중복 제거 후 최신 메타 갱신	공공 API-만개레시피 ID 보존	완료
recipe_ingredient	재료 추출	ingredient_raw에서 재료명·수량·비재료 여부 분리	NER+gazetteer seam	구현
item_master	표준 품목	대표 품목명을 canonical_name으로 관리	전 데이터 조인 허브	구현
item_alias	별칭	원천별 축약·동의를 표준 품목에 연결	이름 기반 조인의 오탐 감소	구현
retail_product	상품명	브랜드·수식어·규격을 분리해 normalized_name 생성	상품↔품목 연결	구현
retail_product	규격	weight_gram-volume_ml·개수 단위 파싱	단위가격 비교 선행조건	구현
retail_price	가격	통화기호 제거, 원가·판매가·할인을·딜종류 구조화	가격이력 및 알림	구현
food_nutrition	영양	제공량 기준 열량·탄단지·당·나트륨 수치화	식약처 필드 매핑	구현
shelf_life_reference	소비기한	보관방식과 최소/최대 일수를 행 단위로 정규화	FoodKeeper wide 구조 해소	구현
cart_item	장바구니	상품·레시피·표준품목 참조를 선택적으로 저장	구매 경로별 nullable FK	구현

데이터 검증과 중복 매핑 리스크

품목명 공간: 레시피 자유텍스트·상품 판매명·영수증 POS 축약명·식약처 표준명이 서로 다름		
조인	상태	내용
재료명 ↔ ITEM_MASTER	보강 중	gazetteer-alias로 exact 우선 매칭, 미매칭 후보는 검토 큐
상품명 ↔ ITEM_MASTER	보강 중	normalized_name과 용량 파서를 함께 사용; 브랜드 수식어만으로 매칭 금지
OCR 품목 ↔ ITEM_MASTER	사용자 확인	오인식 가능성이 높아 confirmed 전 자동 확정 금지
ITEM_MASTER ↔ 영양정보	검증 필요	기관 식품코드와 내부 item_id가 달라 이름·분류 기반 매핑 필요
품목 ↔ 소비기한	부분 커버리지	보관방식이 같을 때만 참조; 값 부재 시 임의 만료일 생성 금지
상품 ↔ 가격이력	확정	retail_product_id와 crawled_at으로 이력 연결
레시피 ↔ 추천노출	확정	recipe_id·user_id·session_id로 노출과 행동 연결

OCR-AI 파이프라인 선처리

본 시스템에서 발생하는 개인정보는
개인정보 조건을 적용한다.

컴포넌트	입력 전처리	출력 후처리	검증	상태
영수증 OCR	이미지 형식 크기 확인, 영수증 영역 인식	품목명·수량·가격·식품 여부 구조화	사용자 confirmed 및 합계 교차검증	구현
영상 레시피	YouTube URL 검증, 자막/설명 추출	재료·조리순서 JSON 생성 후 USER_RECIPE 연결	작업 status/result 보존	구현
재료 NER	ingredient_raw 정리와 사전 후보 생성	item_id·ner_status·is_non_ingredient 기록	색상·도구 등 비재료 가드	구현
가격 이상탐지	상품별 시계열 정렬·최소 표본 확인	이상가격 이벤트 및 알림 후보 생성	baseline 부족 시 과신 금지	구현
리뷰 감정분류	리뷰 텍스트 정제·길이 제한	감정점수·모델 정보 저장	빈 리뷰·모델 실패 분리	구현
리뷰 요약	유효 리뷰 묶음과 주의표현 필터	요약·주의사항·모델명 저장	원문과 파생결과 분리	구현
추천 랭킹	재고·임박도·비용·요청문맥 특징 생성	순위와 구성 점수 impression에 저장	노출 당시 점수 재현	구현
챗봇	개인정보·의도·품목 span 추출	답변 근거 unanswered 상태 저장	동의와 보존기간 적용	구현